

- 小登对学长耐心批改、给出建议表示万分感谢。
- 本小登无任何Python基础，本题绝大部分由 AI 辅助学习，另外还观看了部分题目中给出的B站教学视频合集、查阅了相关资料。
- 源代码、学习笔记所有内容均为古法手搓，不存在任何复制粘贴情况。
- 与 GPT 的对话链接
 - <https://chatgpt.com/share/6ab100e2-746c-83ee-b4d9-305c1ba23db8>
 - <https://chatgpt.com/share/6ab2aa02-acec-83e8-bec8-97ce625b1b72>
- 本学习笔记只针对题目要求的学习笔记内容，学习随笔在另一个pdf。

学习笔记

数据清洗和特征处理方法

- 直接删去 PassengerId、Name、Ticket
 - 有观点认为 **Name** 中包含身份等信息，可能对存活率有影响，在本次模型训练过程中，为了防止过拟合、简化模型训练，选择直接删去。
- 对 字符 类特征的处理：
 - **Sex**：由于只有 male/female 两种类型，选择直接编码，其中 female 编码为 1，male 编码为 0。
 - **Cabin**：此类特征缺失较多，可以做 **删除** 或者进行 **特征工程**，提取新的特征。
 - 本模型训练选择进行 **特征工程**，将 **有客舱号** 编码为 **1**，**无客舱号** 编码为 **0**。
 - 原因：
 - **Cabin** 对存活率影响较大，直接删除并不合适，但是由于 **缺失值过多**，无法通过选取众数填补，这会给模型带来 **大量虚假、不存在的信息** 影响模型预测的准确性。
 - 同时，**对所有客舱号进行独热编码不现实**。
 - 查询资料并与 GPT 对话后，了解到这种情况下，**能否被记录** 可能与 **存活率** 有关，于是选择将 **有 Cabin** 记作 **1**，**无 Cabin** 记作 **0**。
 - **Embarked**：本特征存在 **少量缺失值**，并且属于 **字符串** 类型数据，可以选择 **用众数填补缺失值**。由于本特征有 **多个类型**，我们利用 **独热编码** 将 **从哪个港口出发** 转化为 **是否在 Q/C/S 港口出发**。
- **对 数字 类特征的处理
 - **Age、SibSp、Parch、Fare** 由于这四类数据存在 **不同数据之间数值差距过大/存在极端值** 的问题，选择对这四类数据进行 **z-score 标准化**。
 - 其中 **Age** 存在极少量缺失。由于 Age 存在 **极端值**，平均数可能并不能很好的反应 Age 总体情况，但是中位数不受极端值影响，在比较平均值和中位数后，选择用 **中位数填补**。
 - **Fare** 的数值本来就分布在 **1~3** 之间，**数值较小，且无极端值**，因此不对它做处理

模型结构、激活函数、损失函数、优化器及主要超参数

- **模型结构**: 选择使用 **三层神经网络**，输入 **10 个特征**，其中 **隐藏层** 设置 **16个神经元**。
- **激活函数**：**ReLU函数**。
- **损失函数**：**二元交叉熵**
- **优化器**：**Adam 优化器**
 - 本小登尝试了SDG、动量法和 Adam 优化器，其中 **Adam 优化器的准确率最高、计算资源少**。
- **主要超参数**
 - **神经网络层数**：**3**
 - **隐藏层神经元个数**：**16**

- 本小登尝试使用三层神经网络，隐藏层 **20 个神经元**，训练 **2500 轮次**（过拟合临界点），但得到的测试集、训练集准确率与三层，16 个，1000 轮次基本相同，但 **计算资源远大于后者**。
- **学习率**：0.001
 - 本小登尝试使用 **学习率** 为 0.1、0.01、0.0001，前两者过大，产生了 **损失、准确率震荡**，后者 **过小，训练太慢，计算资源花费大**。
- **epoch**：790(790后训练效果不明显 1000后出现 **明显的过拟合**)
- **batch**：32（训练集最后一个为 8，测试集最后一个为 19）
 - 本校小登也尝试使用 **16、32、48** 作为 batch，但是反复调整学习率和轮次之后，**测试集准确率均在 86% 左右**，但是 **32 所需的训练批次少，计算资源少**。

数据划分方式、随机种子和实验配置

- **数据划分方式**：
 - 依据是否存活，利用 scikit-learn 分层随机划分数据集。
 - **数据集样本数**：891
 - **训练集样本数(712)：测试集样本数(179) $\approx 4:1$** 。
- **随机种子**：
 - 种子设置为 **88**。
 - 使用 scikit-learn 分层随机划分数据集，使用此随机种子。
 - PyTorch 随机初始化权重、偏置等时，使用此随机种子。
- **实验配置**
 - Python 3.14.4
 - PyTorch 2.14.0+cpu
 - Pandas 3.0.6
 - Matplotlib 3.11.2
 - scikit-learn 1.9.1

训练过程中遇到的问题及解决方法

- **训练初期测试集准确率稍高于训练集准确率**
 - 通过与 GPT 对话，了解到 **训练初期概率在 0.5 附近波动**，但是 **很小的概率差别**，就可以让 **预测结果在 0/1 之间切换**，而测试集可能碰巧比较“容易预测”，因此可能出现这种情况。
- **测试集准确率波动比训练集更大**
 - 经分析，因为 **测试集的样本个数明显小于训练集**，前者每个样本预测的对错，对 **准确率的影响**（前者 0.56% 左右，后者 0.14% 左右）大于后者，而 **碰巧多预测对/错几个**，前者波动会明显大于后者。
- **female 生存率明显大于 male 生存率**
 - 通过 Google 搜索，查到 泰坦尼克号救援过程中，实行 **“Women and children first”**，因此 female 生存率明显大于 male 生存率并不奇怪。
- **预测模型时因数据类型报错**
 - 完善代码过程中，预测时若输入 Age = ""，此时将 Pandas DataFrame 转化为 Tensor 的时候出现报错。
 - 将报错结果喂给 GPT，得出 Age 输入为空的时候，经过 **if** 判断，**"Age" = None**，在 DataFrame 表格中，把数据类型判断为 **object** 后来虽然进行了数据填补，但是数据类型仍然没有变。中间经过 Numpy 时，又转化为了 **numpyobject 类型**。而 PyTorch 的：
torch.tensor(...) 不能把这种包含 numpy.object 的数组直接转换成 Float32 Tensor。

- 解决方法：在 Age 缺失值填补后使用 `.astype(float)` 转换为数值类型，并在最终 Tensor 转换前再次保证全部模型输入特征均为浮点数。
 - `new_data["Age"] = new_data["Age"].astype(float)`
 - `new_data = new_data.astype(float)`
- 其他思考：为什么在 训练数据时不报错？
 - 在整个数据集中 Age 缺失极少，虽然此时某些样本的 "Age" 数据类型为 object，但是由于绝大多数的数据为浮点数 所以转化时 忽略了这个特殊情况，从而完成转化，没有报错。
 - 而预测时，只输入了一个乘客的特征，没有其他相同数据作参照，所以会直接报错。

测试集准确率、实验结果分析和心得体会

- 测试集准确率：0.8659217877094972
- 实验结果分析：
 - 准确率
 - 训练集：0.851123595505618
 - 测试集：0.8659217877094972
 - 准确率达到 85% 以上，模型有一定的预测能力。
 - Loss 曲线：训练 前期下降较快，后期趋于平缓；曲线 整体平滑，没有较大的波动，即 几乎不存在损失震荡。
 - 训练前期测试集表现稍好于测试集，后期二者几乎相等。
 - 不存在明显的过拟合现象。
 - 模型局限
 - 本模型 神经网络简单，不能做 高精度 的预测，预测准确率并不高。